

统计方法 理论作业3

1. 证明: 根据题意, 由数据已经被标准化, 可得 $\sum_{i=1}^n X_i = 0$ ~~$\sum_{i=1}^n X_i^T X_i = 0$~~ $(i=1, 2, \dots, p)$

$$SS_R = \sum_{j=1}^n (\hat{X}_{ji} - \bar{X}_j)^2 = \sum_{j=1}^n \hat{X}_{ji}^2 = \hat{X}_j^T \hat{X}_j$$

其中 $\hat{X}_j = X_j \beta = X_j (X_{sj}^T X_{sj})^{-1} X_{sj}^T \cdot X_j$

因为这里 X_j 为因变量
线性模型, 估计即可

$X_{sj} = [X_1 \ X_2 \ \dots \ X_{j-1} \ X_{j+1} \ \dots \ X_p]$
除去了第 j 列

故 $SS_R = \hat{X}_j^T \hat{X}_j$

$$= X_j^T X_{sj} (X_{sj}^T X_{sj})^{-1} X_{sj}^T \cdot X_{sj} (X_{sj}^T X_{sj})^{-1} X_{sj}^T \cdot X_j$$

$$= X_j^T X_{sj} (X_{sj}^T X_{sj})^{-1} X_{sj}^T X_j$$

同时 $SS_T = \sum_{k=1}^n (X_{jk} - \bar{X}_j)^2 = \sum_{k=1}^n X_{jk}^2 = 1$

该回归模型的复决定系数 $R_j^2 = \frac{SS_R}{SS_T} = X_j^T X_{sj} (X_{sj}^T X_{sj})^{-1} X_{sj}^T X_j$

现在只需证明 $C_{jj} = \frac{1}{1 - R_j^2}$ $R_j^2 = \dots$ 即可证原式。

X_{sj} 除去了 X_j , 我要把 X_j 抽出来, 才能保证顺序不乱,
而且这个 C 又来源于 X_s 而不是 X_{sj} , 所以要尽量找一些联系。

$X_s = [X_j \ X_{sj}] \cdot A_j \rightarrow$ 由线性知识, A_j 为初等矩阵 (把 I_p 的第 j 列换到第 1 列, 第 $1-j-1$ 列往后推一列)

$$C = (X_s^T X_s)^{-1} = (A_j^T \begin{bmatrix} X_j^T \\ X_{sj}^T \end{bmatrix} [X_j \ X_{sj}] A_j)^{-1}$$

$$= A_j^{-1} \begin{bmatrix} 1 & X_j^T X_{sj} \\ X_{sj}^T X_j & X_{sj}^T X_{sj} \end{bmatrix}^{-1} (A_j^T)^{-1}$$

$A_j^{-1} = A_j^T$ (A_j 就是对行施加类似的操作即可)

这里我搞反了!!!

$X_s \cdot A_j = [X_j \ X_{sj}]$ $C = (X_s^T X_s)^{-1} = (A_j \begin{bmatrix} X_j^T \\ X_{sj}^T \end{bmatrix} [X_j \ X_{sj}] A_j^T)^{-1}$

$X_s = [X_j \ X_{sj}] A_j^T$

$$= A_j \begin{bmatrix} 1 & X_j^T X_{sj} \\ X_{sj}^T X_j & X_{sj}^T X_{sj} \end{bmatrix}^{-1} A_j^T$$

A_j 左乘, 意味着第 1 行放到第 j 行, 然后 $2-j$ 行往前移一行
 A_j^T 右乘, 意味着第 1 列放到第 j 列, 然后 $2-j-1$ 列往前移一列

$$B = \begin{bmatrix} 1 & X_j^T X_{sj} \\ X_{sj}^T X_j & X_{sj}^T X_{sj} \end{bmatrix}^{-1}$$

那什么 C_{jj} 代表的是 B 的第 1 行第 1 个元素!!!
根据逆矩阵的公式 (分块)

可得 $C_{jj} = \frac{1}{1 - X_j^T X_{sj} (X_{sj}^T X_{sj})^{-1} X_{sj}^T X_j}$

再与之前求得的 R_j^2 比较, 即可得原式得证。

2. 解: $MSE(\hat{\beta}) = E((\hat{\beta} - \beta)^T (\hat{\beta} - \beta)) \leftarrow E(\hat{\beta}) = \beta$

这都是线性回归模型
的性质

$$= E((\hat{\beta} - E(\hat{\beta}))^T (\hat{\beta} - E(\hat{\beta})))$$

← $\text{Cov}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$

$$= \text{TR}(\text{cov}(\hat{\beta}))$$

$$= \text{Tr}(\text{cov}(F))$$
$$= \text{Tr}(f^2 (X^T X)^{-1}) = f^2 \text{Tr}((X^T X)^{-1})$$

3. 证明: 这个题主要应该去在贝叶斯估计角度证明这个解与岭回归课上学到的岭回归模型之等价性。得到一个解, 然后证明它与

课上学到的岭回归模型:

$$\hat{\beta}(k) = (X^T X + kI)^{-1} (X^T X) \hat{\beta}$$

然后, 我们从最本质的问题开始推

最本质: 由题 $y_i \sim N(\beta_0 x_i + \dots + \beta_p x_{ip}, \sigma^2)$

可以看到, β_0 压根不考虑了,

$$\text{取 } X = \begin{bmatrix} x_1^T \\ \vdots \\ x_n^T \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

$$y_i | x_i, \beta$$

$$\sim N(\beta^T x_i, \sigma^2)$$

感觉应该是

$$y_i \sim N(\beta_0 x_{i1} + \dots + \beta_p x_{ip}, \sigma^2)$$

$$\text{取 } \beta \sim N(0, \Sigma)$$

$$P(y | X, \beta) = \prod_{i=1}^n P(y_i | x_i, \beta) = \frac{1}{(\sqrt{2\pi})^n \sigma^n} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta^T x_i)^2 \right\}$$

$$\text{其中转化为矩阵形式 } \sum_{i=1}^n (y_i - \beta^T x_i)^2 = [y_1 - \beta^T x_1 \quad y_2 - \beta^T x_2 \quad \dots \quad y_n - \beta^T x_n] \begin{bmatrix} y_1 - \beta^T x_1 \\ \vdots \\ y_n - \beta^T x_n \end{bmatrix}$$

$$= (X^T X (y^T - \beta^T X^T) \cdot (y - X\beta))$$

$$= y^T y - y^T X \beta - \beta^T X^T y + \beta^T X^T X \beta$$

$$= y^T y + \beta^T X^T X \beta - 2\beta^T X^T y \quad (\text{因为 } y \text{ 的维数 } n \times 1)$$

$$\text{故 } P(y | X, \beta) = \frac{1}{(\sqrt{2\pi})^n \sigma^n} \exp \left\{ -\frac{1}{2\sigma^2} (y^T y + \beta^T X^T X \beta - 2\beta^T X^T y) \right\}$$

$$\pi(\beta) = \frac{1}{\sqrt{2\pi} |\Sigma|^{\frac{1}{2}}} \exp \left(-\frac{1}{2} \beta^T \Sigma^{-1} \beta \right)$$

由贝叶斯估计:

$$P(\beta | X, y) = \frac{P(\beta, X, y)}{P(X, y)} = \frac{P(y | X, \beta) \cdot P(X | \beta) \cdot \pi(\beta)}{P(X, y)}$$

$$\propto P(y | X, \beta) \cdot \pi(\beta) = \frac{1}{(\sqrt{2\pi})^{n+1} \sigma^n |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} (y^T y + \beta^T X^T X \beta - 2\beta^T X^T y) - \frac{1}{2} \beta^T \Sigma^{-1} \beta \right\}$$

$$f(\beta) = -\log L(\beta) = -\log \left((\sqrt{2\pi})^{n+1} \sigma^n |\Sigma|^{\frac{1}{2}} \right) - \frac{1}{2\sigma^2} (y^T y + \beta^T X^T X \beta - 2\beta^T X^T y) - \frac{1}{2} \beta^T \Sigma^{-1} \beta$$

设其为 $L(\beta)$

虽然一般来说此时得到了 β 的后验概率分布, 应该对其期望作为贝叶斯估计值
 $\hat{\beta} = \arg\max_{\beta} f(\beta)$ $f(\beta)$ 为似然函数 $\nabla_{\beta} f(\beta) = -\frac{1}{2\sigma^2} (2X^T X \beta - 2X^T y)$

令 $\nabla_{\beta} f(\beta) = 0$ 可得 $\hat{\beta} = (X^T X + \delta^2 \Sigma^{-1})^{-1} X^T y$ ①

课上学到的岭回归估计的具体 β : $\hat{\beta} = (X^T X + kI)^{-1} X^T y$ ②

比较①和② 令 $\delta^2 \Sigma^{-1} = kI$ 即岭参数, δ^2, Σ^{-1} 关联起来.
结构类似, 终于, 我从贝叶斯估计的角度证明了岭回归的合理性.