

Q1

我们已经知道, c_{jj} 作为方差扩大因子, 满足

$$Var(\hat{\beta}_j) = \frac{c_{jj}}{l_{jj}} \sigma^2$$

对于标准化后的样本, 事实上

$$Var(\hat{\beta}_j) = c_{jj} \sigma^2$$

另一方面, 在线性回归中, 我们有

$$Var(\hat{\beta}_j) = \sigma^2 (X'_s X_s)_{jj}^{-1}$$

不失一般性, 我们假设 $X_s = (X_j, x_j)$, 即 x_j 是标准化后的最后一个特征, 我们有

$$(X'_s X_s)^{-1} = \begin{pmatrix} X'_j X_j & X'_j x_j \\ x'_j X_j & x'_j x_j \end{pmatrix}^{-1} \quad (1)$$

$$= \begin{pmatrix} E_{11} & E_{12} \\ E_{21} & E_{22} \end{pmatrix} \quad (2)$$

这是一个分块矩阵的逆, 因为我们关心的是 $(X'_s X_s)_{jj}^{-1}$ 这一对角元, 因此我们只关心其中 E_{22} 的结果, 利用分块矩阵求逆公式, 我们有

$$E_{22} = (x'_j x_j - x'_j X_j (X'_j X_j)^{-1} X'_j x_j)^{-1} \quad (3)$$

$$Var(\hat{\beta}_j) = \sigma^2 E_{22} \quad (4)$$

我们接下来考察对于 x_j 建立的线性回归的模型的性质, 我们发现 X_j 是这一回归模型的设计矩阵, 记模型的帽子矩阵为 $H_j = X_j (X'_j X_j)^{-1} X'_j$, 由于 $\sum_i x_{ij} = \bar{x}_j = 0$, $\sum_i x_{ij}^2 = 1$, 我们有

$$SS_{Rj} = \sum_i (\hat{x}_{ij} - \bar{x}_j)^2 \quad (5)$$

$$= \sum_i \hat{x}_{ij}^2 \quad (6)$$

$$= x'_j H'_j H_j x_j \quad (7)$$

$$SS_{Tj} = \sum_i (x_{ij}^2 - \bar{x}_j^2) \quad (8)$$

$$= \sum_i x_{ij}^2 \quad (9)$$

$$= 1 \quad (10)$$

$$R_j^2 = \frac{SS_{Rj}}{SS_{Tj}} \quad (11)$$

$$= x'_j H'_j H_j x_j \quad (12)$$

利用上面的讨论, 我们重新考察 E_{22} 的值, 注意其中 $x'_j x_j = \sum_i x_{ij}^2 = 1$, 我们有

$$E_{22} = (x'_j x_j - x'_j X_j (X'_j X_j)^{-1} X'_j x_j) \quad (13)$$

$$= (x'_j x_j - x'_j H_j x_j) \quad (14)$$

$$= (x'_j x_j - x'_j H'_j H_j x_j) \quad (15)$$

$$= (1 - R_j^2)^{-1} \quad (16)$$

$$Var(\hat{\beta}_j) = \sigma^2 (1 - R_j^2)^{-1} \quad (17)$$

同时，我们知道 $Var(\hat{\beta}_j) = c_{jj}\sigma^2$ ，所以

$$c_{jj} = \frac{1}{1 - R_j^2}$$

Q2

我们知道， $E(\hat{\beta}) = \beta$

$$MSE(\hat{\beta}) = E(\hat{\beta} - \beta)'(\hat{\beta} - \beta) \quad (18)$$

$$= E(\hat{\beta}'\hat{\beta} - \beta'\hat{\beta} - \hat{\beta}'\beta + \beta'\beta) \quad (19)$$

$$= E(\hat{\beta}'\hat{\beta}) - \beta'\beta - \beta'\beta + \beta'\beta \quad (20)$$

$$= E(\hat{\beta}'\hat{\beta}) - \beta'\beta \quad (21)$$

同时，我们知道 $E(\hat{\beta}'\hat{\beta}) = Tr(Var(\hat{\beta})) + \hat{\beta}'\hat{\beta} = Tr(\sigma^2(X'X)^{-1}) + \hat{\beta}'\hat{\beta}$ ，所以

$$MSE(\hat{\beta}) = Tr(\sigma^2(X'X)^{-1}) \quad (22)$$

$$= \sigma^2 Tr((X'X)^{-1}) \quad (23)$$

对于满秩实对称阵 $X'X$ ，我们记它的特征值为 $\lambda_1, \dots, \lambda_p$ ，则它的逆矩阵的特征值为 $\frac{1}{\lambda_p}, \dots, \frac{1}{\lambda_1}$ ，于是我们有

$$Tr((X'X)^{-1}) = \frac{\sum_i \lambda_i}{\prod_i \lambda_i} \quad (24)$$

$$= \frac{Tr(X'X)}{|X'X|} \quad (25)$$

因为 y 经过中心化， X 经过标准化，所以我们这里的 X 为标准化之后的 X_s ，且 β 不含截距项， X_s 的维度为 $n \times p$ ，且 $X_s'X_s$ 的对角元全为1，所以 $Tr(X'X) = p$ ，则

$$MSE(\hat{\beta}) = \frac{\sigma^2 p}{|X'X|}$$

上面的结果同样告诉我们，当样本共线性较强时，参数估计的均方误差也会很大。

Q3

我们已经知道，岭回归估计 $\hat{\beta}(k)$ 是下面这个优化问题的解：

$$\hat{\beta}(k) = \arg \min_{\beta} (y - X\beta)'(y - X\beta) + \lambda \beta' \beta$$

我们在这里讨论标准化后的 X 与中心化后的 y ，即不考虑截距项 β_0 ，则有

$$\hat{\beta}(k) = \arg \min_{\beta} \left(\sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda \sum_{i=1}^p \beta_i^2 \right)$$

上式是我们已有的岭回归的定义，现在我们从贝叶斯统计来解决线性回归的问题，我们采用贝叶斯估计中常见的最大后验估计的方法，即

$$\hat{\beta}_{bayes} = \arg \max_{\beta} P(\beta|y)$$

我们接下来开始计算最大化后验估计的结果，我们认为每个参数 β_i 服从的先验分布为正态分布，且相互独立，即 $\beta_i \sim \mathcal{N}(0, \tau^2)$, $i = 1, \dots, p$ ，同时假定数据分布为 $y_i \sim \mathcal{N}(x_i \beta, \sigma^2)$, $i = 1, \dots, n$

$$\hat{\beta}_{bayes} = \arg \max_{\beta} P(\beta|y) \quad (35)$$

$$= \arg \max_{\beta} P(\beta)P(y|\beta) \quad (36)$$

$$= \arg \max_{\beta} (\ln P(\beta) + \ln P(y|\beta)) \quad (37)$$

$$= \arg \max_{\beta} \left(\sum_{i=1}^p -\frac{\beta_i^2}{2\tau^2} - \sum_{i=1}^n \frac{(y_i - x'_i\beta)^2}{2\sigma^2} \right) \quad (38)$$

$$= \arg \max_{\beta} \left(\sum_{i=1}^p -\frac{\sigma^2\beta_i^2}{\tau^2} - \sum_{i=1}^n (y_i - x'_i\beta)^2 \right) \quad (39)$$

$$= \arg \max_{\beta} \left(\frac{\sigma^2}{\tau^2} \sum_{i=1}^p (-\beta_i^2) - \sum_{i=1}^n (y_i - x'_i\beta)^2 \right) \quad (40)$$

$$= \arg \min_{\beta} \left(\frac{\sigma^2}{\tau^2} \sum_{i=1}^p \beta_i^2 + \sum_{i=1}^n (y_i - x'_i\beta)^2 \right) \quad (41)$$

$$= \arg \min_{\beta} \left(\sum_{i=1}^n (y_i - x'_i\beta)^2 + \frac{\sigma^2}{\tau^2} \sum_{i=1}^p \beta_i^2 \right) \quad (42)$$

$$= \arg \min_{\beta} \left(\sum_{i=1}^n (y_i - x_i\beta)^2 + \lambda \sum_{i=1}^p \beta_i^2 \right), \quad \text{let } \lambda = \frac{\sigma^2}{\tau^2} \quad (43)$$

注：

- 式(35)到式(36)的推导中，我们忽略了与 β 无关的分母部分
- 式(37)到式(38)的推导中，我们忽略了与 β 无关的若干项

这样，我们就证明了岭回归的参数估计 $\hat{\beta}(k)$ 是贝叶斯统计下最大化后验分布的估计 $\hat{\beta}_{bayes}$ ，从而从贝叶斯估计的角度解释了岭回归。